

# Wirtschaftsstatistik und Ökonometrie

## Übungsblatt 13

**Abgabe:** Freitag, 07.02.2025 12:00 Uhr in Moodle

**R-Aufgabe 1** ( $3 + 3 + 1 + 1 + 1 + 1 + 1 + 1 + 1 + 1 = 14$  Punkte): Betrachten Sie den Datensatz `homeprice` (`library("UsingR")`), welcher die Variablen

<i>list</i>	Listenpreis (in Tausend \$)
<i>sale</i>	Verkaufspreis (in Tausend \$)
<i>full</i>	Anzahl von komplett ausgestatteten Badezimmern
<i>half</i>	Anzahl von kleinen Badezimmern
<i>bedrooms</i>	Anzahl von Schlafzimmern
<i>rooms</i>	Anzahl von Zimmern insgesamt
<i>neighborhood</i>	Subjektive Beurteilung der Wohngegend (Skala von 1 bis 5)

für 29 im Jahr 2001 verkaufte Häuser in Maplewood, NJ, enthält.

- (a) Testen Sie zu einem Signifikanzniveau von  $\alpha = 5\%$  für das lineare Regressionsmodell

$$sale = \beta_0 + \beta_1 full + \beta_2 rooms + \beta_3 neighborhood + u$$

unter den Annahmen MLR.1-6 die Nullhypothese  $\hat{\beta}_3 = 0$  gegen eine zweiseitige Alternative. Finden Sie das dazugehörige Konfidenzintervall für  $\hat{\beta}_3$  anhand der passenden t-Statistik und zeichnen Sie deren Verteilung (unter  $H_0$ ) in ein Diagramm. Kennzeichnen Sie dabei innerhalb der Abbildung den Ablehnbereich sowie den Wert der Teststatistik.

- (b) Unter den Annahmen MLRA.1-4 und MLRA.5' gilt, dass die Teststatistik asymptotisch normalverteilt ist. Berechnen Sie das entsprechende asymptotische Konfidenzintervall für  $\hat{\beta}_3$  und fügen Sie die Dichte der entsprechenden Normalverteilung in obiges Diagramm ein. Kennzeichnen Sie erneut den entsprechenden Ablehnbereich auf Grundlage dieser asymptotischen Normalverteilung.

- (c) Betrachten Sie die Ergebnisse aus Teil (a) und (b) und vergleichen Sie diese.

- (d) Testen Sie zu einem Signifikanzniveau  $\alpha = 5\%$  für das (unrestringierte) Modell

$$sale = \beta_0 + \beta_1 full + \beta_2 half + \beta_3 bedrooms + \beta_4 rooms + \beta_5 neighborhood + u,$$

ob die Variablen *half* und *bedrooms* gemeinsam einen Einfluss auf den Verkaufspreis haben. Gehen Sie dabei davon aus, dass die Annahmen MLR.1-MLR.6 erfüllt sind und verwenden Sie eine geeignete F-Statistik.

- (e) Testen Sie die Hypothese aus Teil (d) mit dem Lagrange Multiplier Test.

- (f) Unterscheiden sich die  $p$ -Werte für die Tests aus (d) und (e)?

Betrachten Sie nun die folgenden beiden Modelle:

$$sale = \beta_0 + \beta_1 full + \beta_2 rooms + \beta_3 neighborhood + u,$$

$$sale = \beta_0 + \beta_1 half + \beta_2 bedrooms + \beta_3 neighborhood + u.$$

- (g) Welche Korrelation würde man für *full* und *half* bzw. *rooms* und *bedrooms* erwarten? Wie hoch sind die tatsächlichen Korrelationen?
- (h) Sind die Regressoren der Modelle signifikant bzw. gemeinsam signifikant zu einem Niveau von 5%?
- (i) Welches Modell würde bevorzugt werden?
- (j) Würde  $\bar{R}^2$  fallen, falls die Variable *neighborhood* aus den Regressionen entfernt wird? Begründen Sie Ihre Antwort.

**R-Aufgabe 2** (2 + 3 + 1 = 6 Punkte): Betrachten Sie erneut den Datensatz `ergebnisse.txt` von Blatt 12 zusammen mit der linearen Regression

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_1^2 + \beta_3 \log x_2 + \beta_4 x_3 + \beta_5 x_1 x_3 + \beta_6 x_4 + u.$$

Das Signifikanzniveau sei durchweg auf  $\alpha = 5\%$  festgesetzt.

- (a) Welche Regressoren sind unter der Annahme der Homoskedastizität signifikant?
- (b) Welche Regressoren sind unter der Annahme der Heteroskedastizität signifikant? Berechnen Sie dazu die heteroskedastizitätsrobusten Standardabweichungen, t-Statistiken sowie die zugehörigen p-Werte. Unterscheiden sich die Werte stark von denen aus Teil (a)?
- (c) Führen Sie einen White-Test durch, um zu überprüfen, ob in diesem Modell Heteroskedastizität vorliegt. Dabei soll eine Regression von  $\hat{u}_i^2$  auf  $\hat{y}_i$  und  $\hat{y}_i^2$  durchgeführt werden.

**R-Aufgabe 3** (1 + 1 + 3 = 5 Punkte): Die Datei `schule.txt` enthält folgende Daten über 1.692 Schulen in Michigan:

- $y$  Anteil der Viertklässler (in %), die eine ausreichende Note in Mathe erreicht haben (*Bestehen*)
- $x_1$  Anteil der Schüler (in %), die ein kostenloses Mittagessen erhalten haben (*Lunch*)
- $x_2$  Anzahl der Schüler (*Schueler*)
- $x_3$  Ausgaben (in \$) der Schule pro Schüler (*Ausgaben*)

Es wird folgender linearer Zusammenhang vermutet:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \beta_4 \log x_3 + u$$

- (a) Schätzen Sie die Regressionsparameter in **R** mit Hilfe von `lm` und interpretieren Sie  $\beta_1, \beta_2$  und  $\beta_4$  in Worten. Wie sollte man das lineare Modell ändern, um  $\beta_1$  und  $\beta_2$  besser interpretieren zu können.
- (b) Testen Sie mithilfe des Breusch-Pagan-Tests zum Niveau  $\alpha = 0.01$ , ob in diesem linearen Modell Heteroskedastizität vorliegen könnte. (Es soll keine **R**-Funktion verwendet werden, die den Test automatisch durchführt, `lm` darf aber verwendet werden.)
- (c) Schätzen Sie die normale Kovarianzmatrix von  $\hat{\beta}$  und die White-Kovarianzmatrix von  $\hat{\beta}$ . Vergleichen Sie die Standardfehler von  $\hat{\beta}_0, \dots, \hat{\beta}_4$ .

**Hinweis:** Die Lösungen zu den R-Aufgaben müssen ausreichend erklärt werden. Dazu sollte in der .R-Datei, die auf Moodle als Lösung hochgeladen wird, der Code ausreichend kommentiert werden!